Workshop: Web Scraping 2

Abril, 2020

Apresentação

Sobre a Curso-R

Athos Damiani
Curso-R
Bacharel em Estatística

William Amorim
Curso-R
Doutor em Estatística

Fernando Corrêa
Curso-R
Mestrando em Estatística

Julio Trecenti
Curso-R, Terranova, ABJ, Conre
Doutorando em Estatística

Daniel Falbel
Curso-R e RStudio
Bacharel em Estatística

Caio Lente
Curso-R, Terranova, ABJ, Mestrando em ciências da computação

Linha do tempo

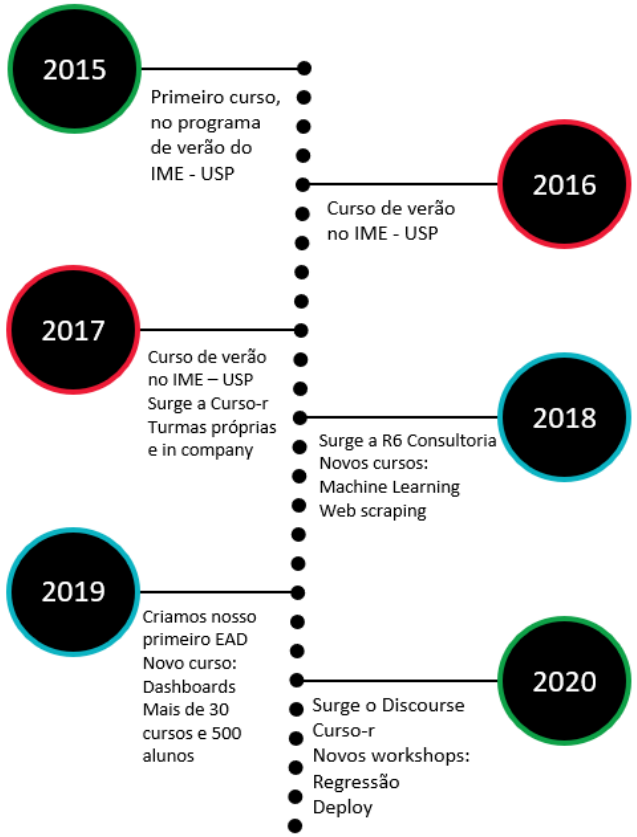

Nossos cursos

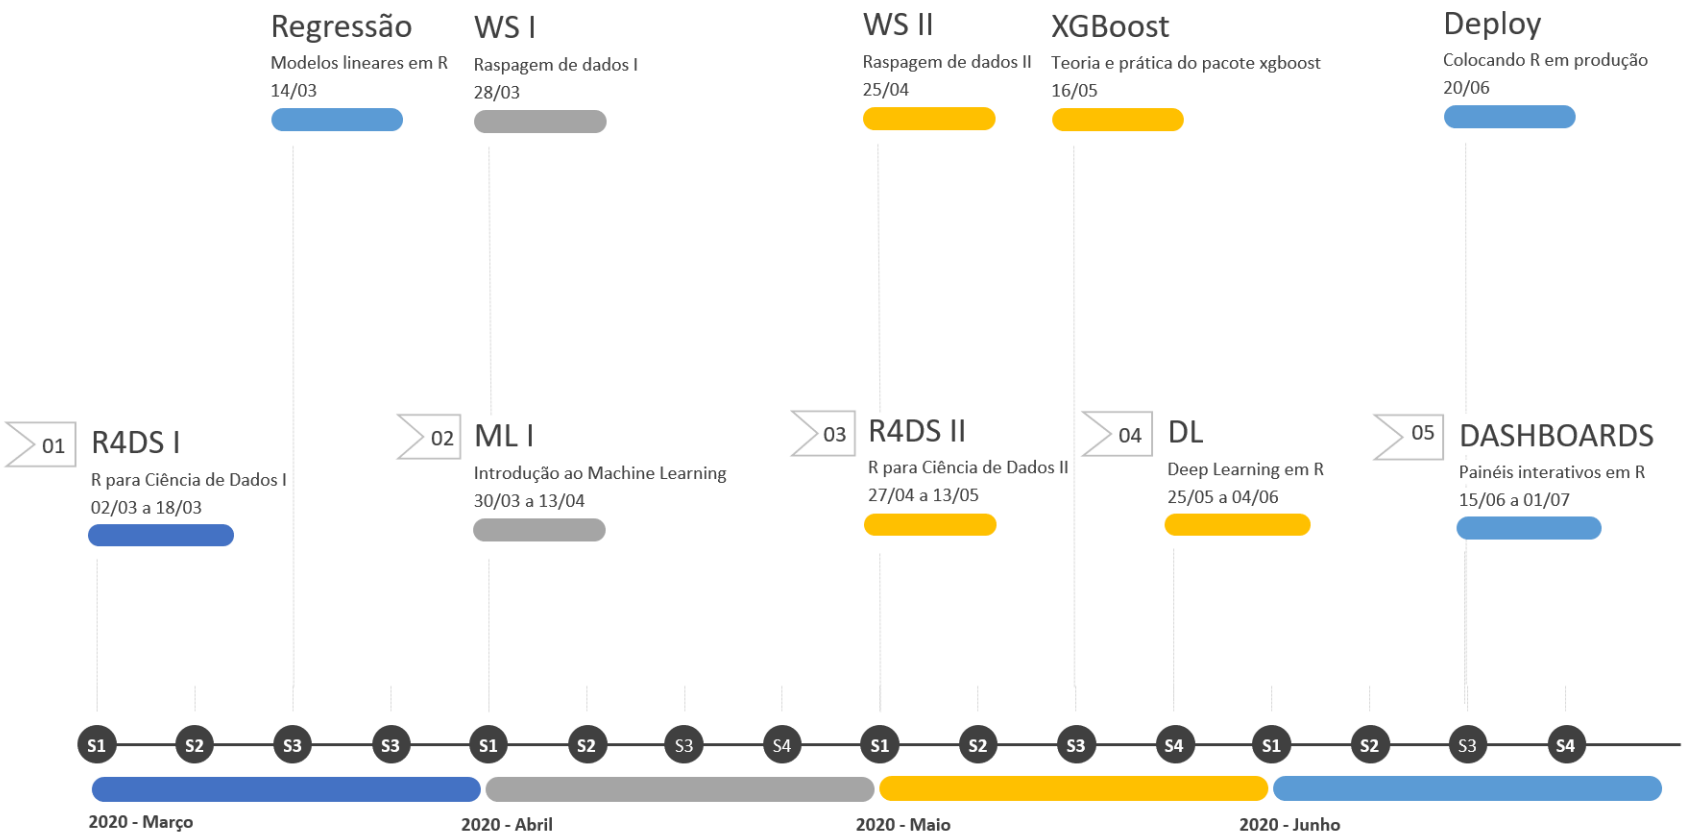

Este curso

- HTML + CSS + XPath
- Iteração + tratamento de erros + agendamento
- Paralelização + futuros
- Selenium + WebDriver + PhantomJS
- SSL + Viewstate + ...
- Exercícios variados no estilo MUY:

    1. (eu) Conceitos/explicações
    2. (nós) Exemplo
    3. (vocês!) Exercício

XPath

Introdução ao HTML

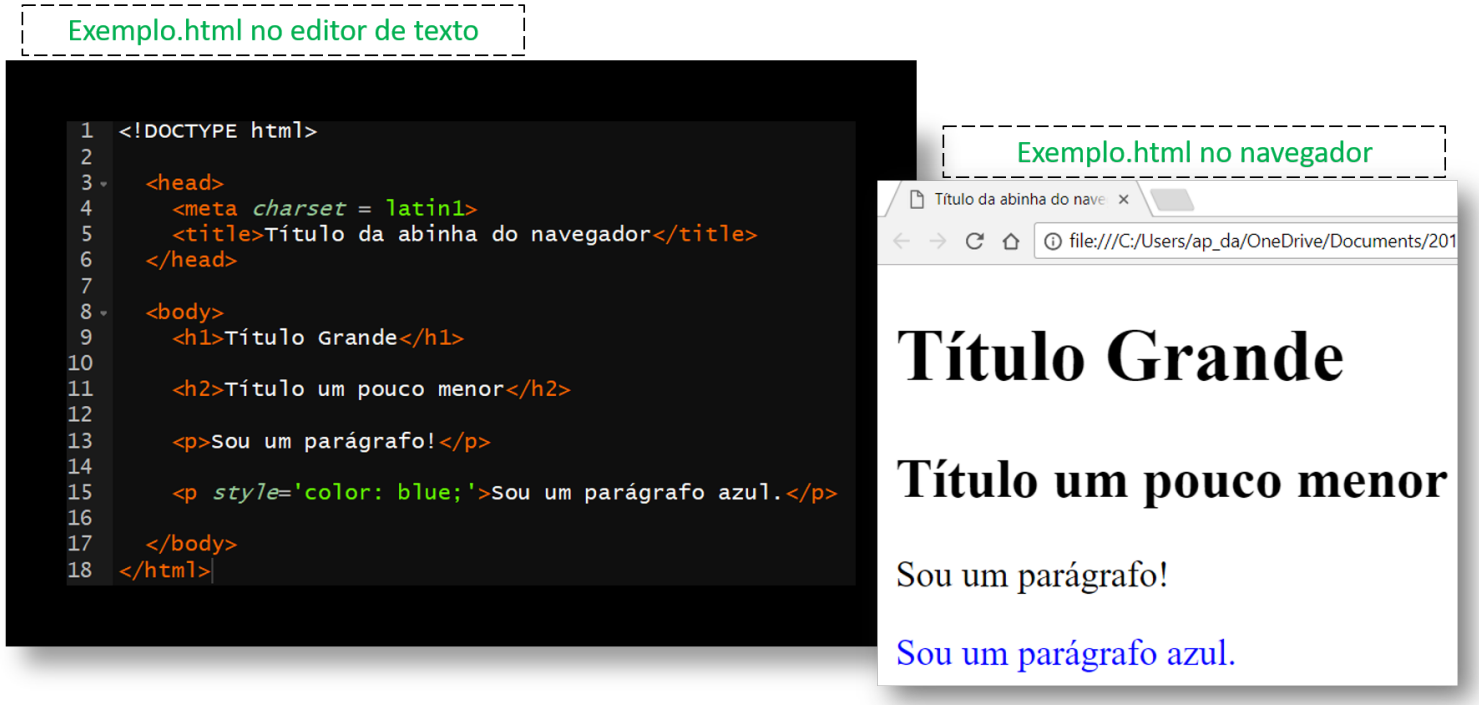

- HTML (*Hypertext Markup Language*) é uma linguagem de markup cujo uso é a criação de páginas web. Por trás de todo site há pelo menos um arquivo `.html`

Introdução ao HTML

Exemplo.html no editor de texto

```
1  <!DOCTYPE html>
2
3  <head>
4    <meta charset = latin1>
5    <title>Título da abinha do navegador</title>
6  </head>
7
8  <body>
9    <h1>Título Grande</h1>
10
11   <h2>Título um pouco menor</h2>
12
13   <p>Sou um parágrafo!</p>
14
15   <p style='color: blue;'>Sou um parágrafo azul.</p>
16
17 </body>
18 </html>
```

Exemplo.html no navegador

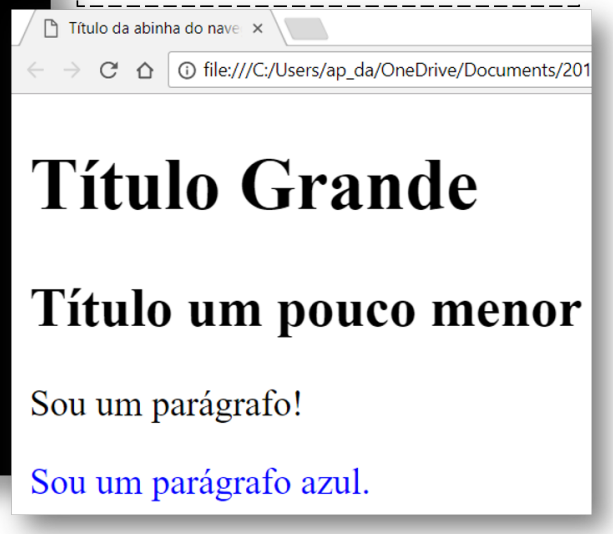

- Todo arquivo HTML pode ser dividido em seções que definirão diferentes aspectos da página: **head** são "metadados", enquanto **body** é o corpo da página

Introdução ao HTML

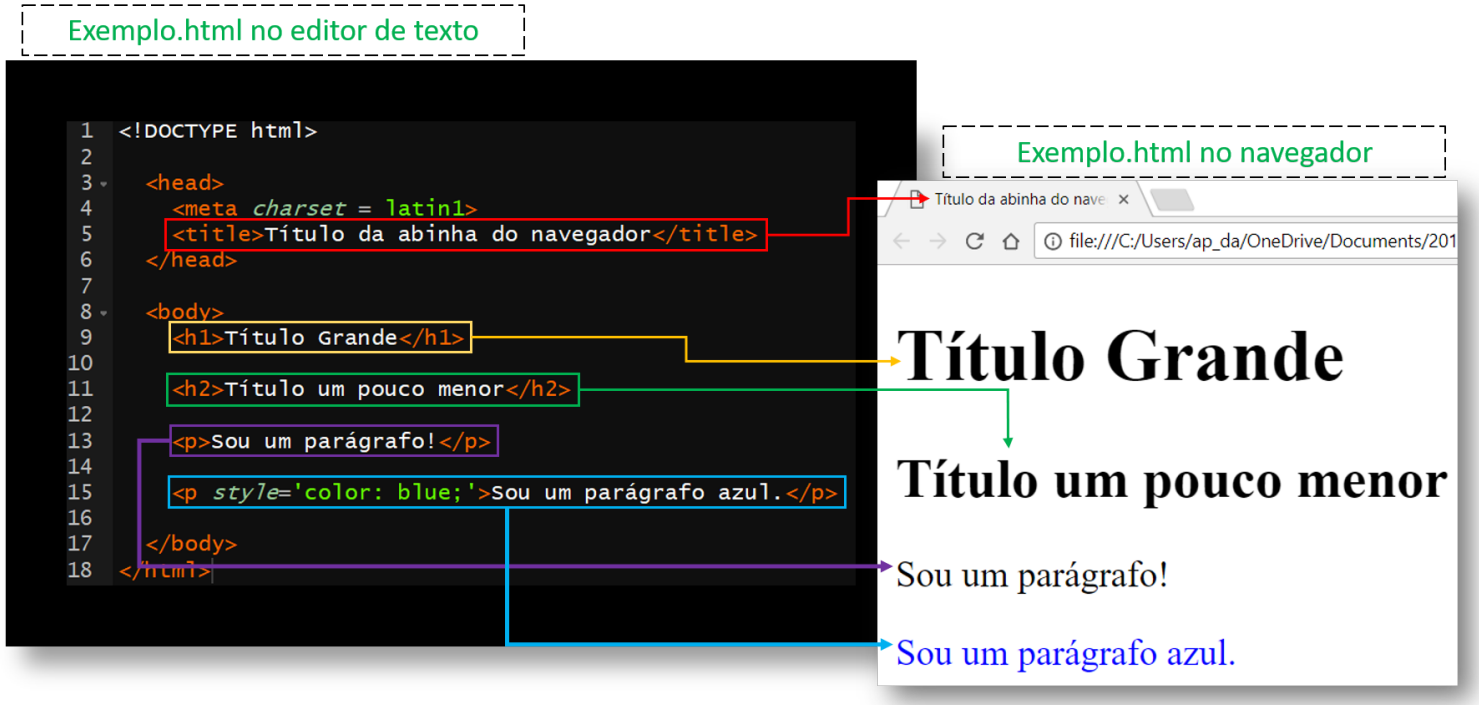

Tags (`head`, `body`, `h1`, `p`, ...) demarcam as seções e sub-seções, enquanto atributos (`charset`, `style`, ...) mudam como essas seções são renderizadas pelo navegador

Introdução ao HTML

- Todo HTML se transforma em um **DOM** (document object model) dentro do navegador.
- Um DOM pode ser representado como uma árvore em que cada *node* é:
  - ou um **atributo**
  - ou um **texto**
  - ou uma **tag**
  - ou um **comentário**
- Utiliza-se a relação de pai/filho/irmão entre os nós.
- Para descrever a estrutura de um DOM, usa-se uma linguagem de markup chamada XML (*Extensible Markup Language*) que define regras para a codificação de um documento.

Introdução ao HTML

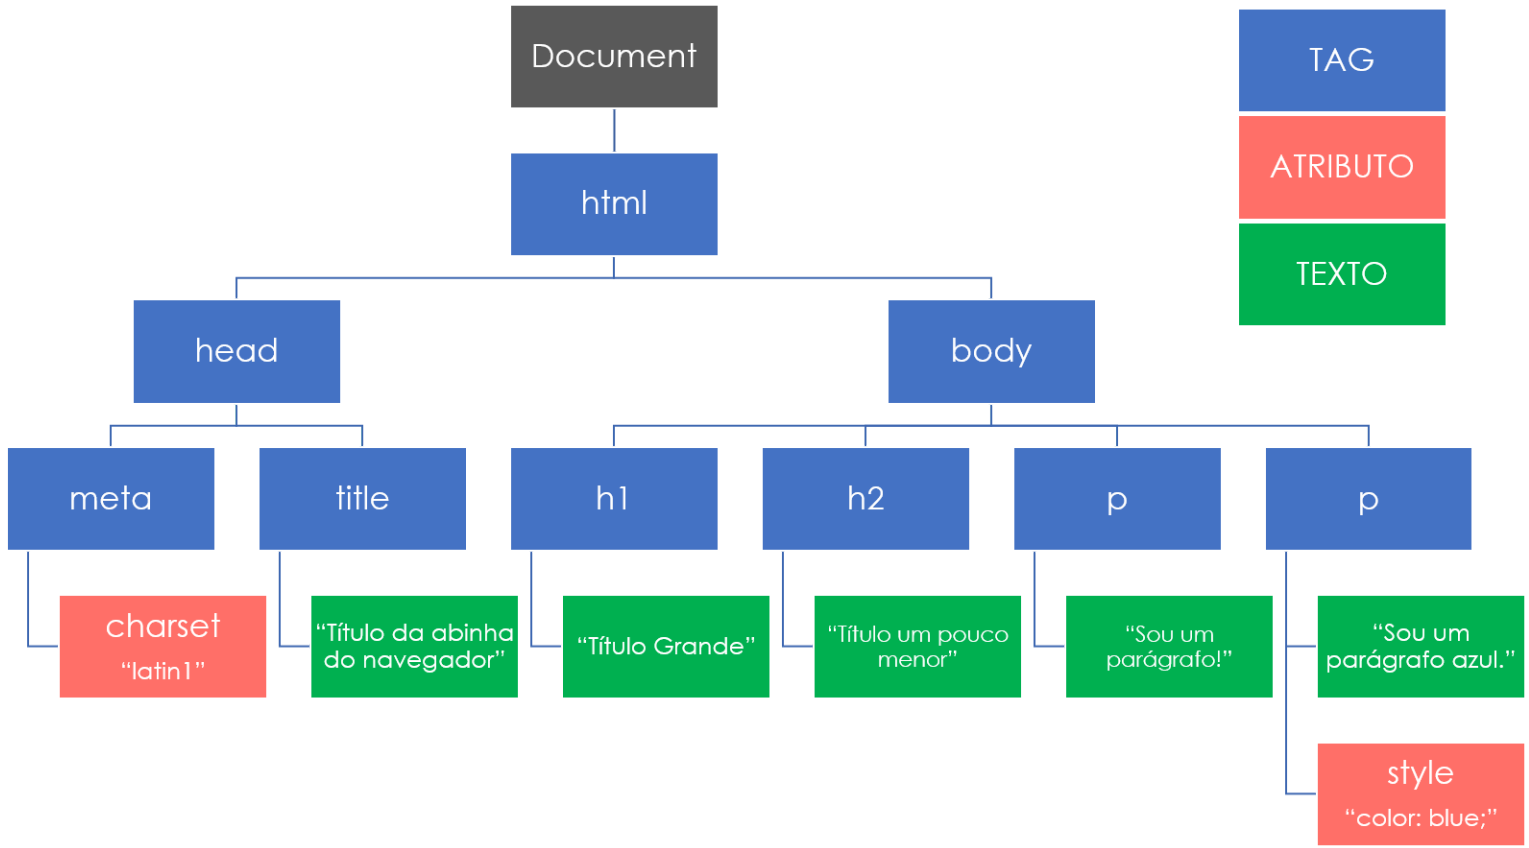

Introdução ao HTML

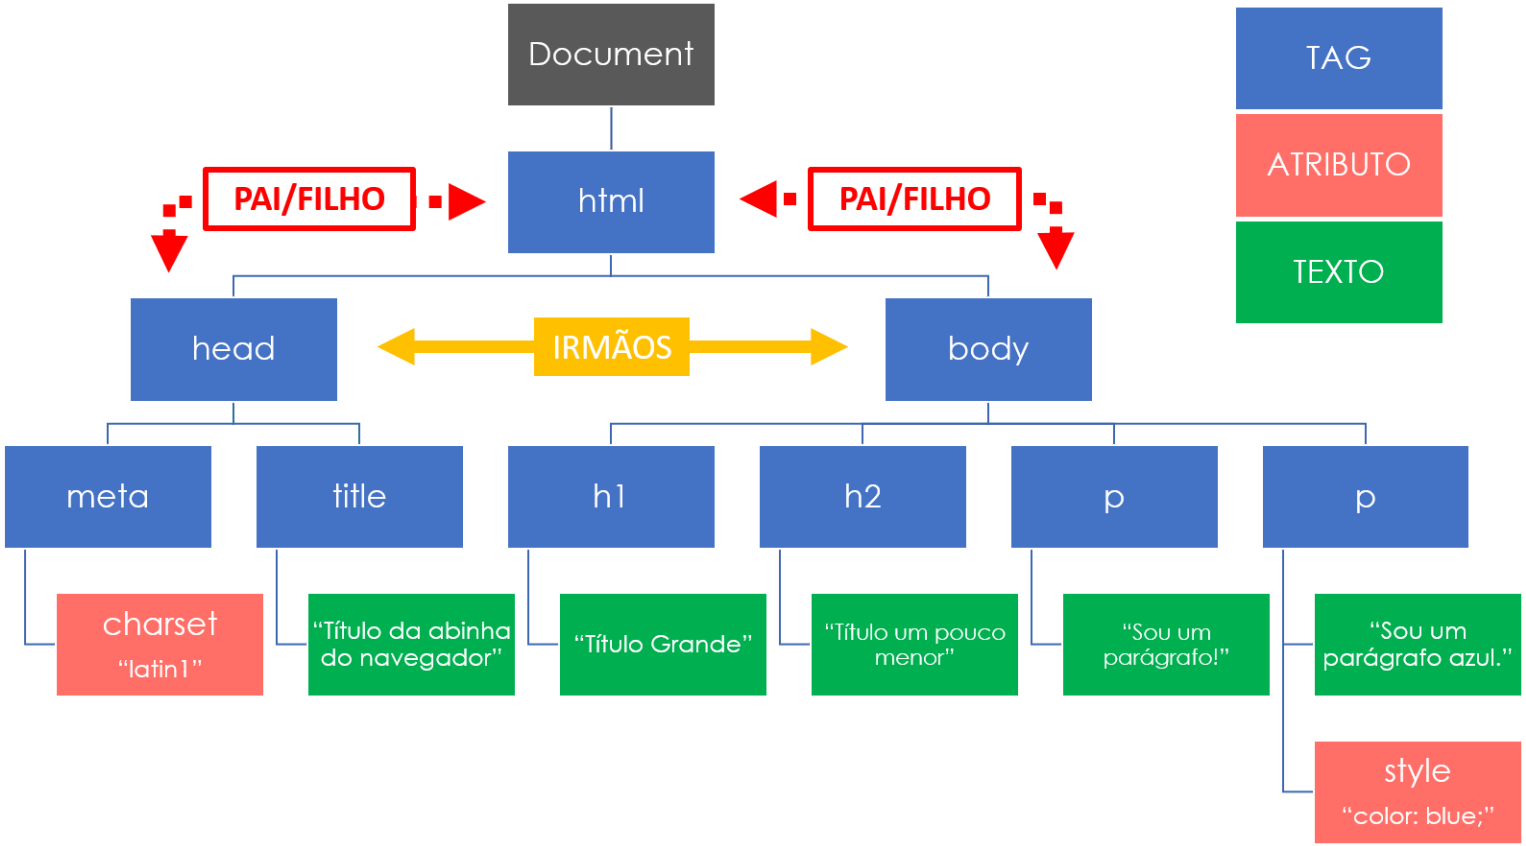

XPath - XML Path Language

- Exemplo: coletando todas as tags <p> (parágrafos)

```
library(xml2)

# Ler o HTML
html <- read_html("static/html_exemplo.html")

# Coletar todos os nodes com a tag <p>
nodes <- xml_find_all(html, "//p")

# Extrair o texto contido em cada um dos nodes
text <- xml_text(nodes)
text
```

```
#> [1] "Sou um parágrafo!"      "Sou um parágrafo azul."
```

XPath - XML Path Language

- Com `xml_attrs()` podemos extrair todos os atributos de um node:

```
xml_attrs(nodes)
```

```
#> [[1]]
#> named character(0)
#>
#> [[2]]
#>          style
#> "color: blue;"
```

```
xml_attr(nodes, "style")
```

```
#> [1] NA             "color: blue;"
```

XPath - XML Path Language

- Já com `xml_children()`, `xml_parents()` e `xml_siblings()` podemos acessar a estrutura de parentesco dos nós:

```
heads <- xml_find_all(html, "head")
xml_siblings(heads)
```

```
#> {xml_nodeset (1)}
#> [1] <body>\n    <h1>Título Grande</h1>\n    \n    <h2>Título um pouco menor</ ...
```

```
xml_children(heads)
```

```
#> {xml_nodeset (3)}
#> [1] <meta http-equiv="Content-Type" content="text/html; charset=UTF-8">\n
#> [2] <meta charset="latin1">\n
#> [3] <title>Título da abinha do navegador</title>
```

CSS

- CSS (Cascading Style Sheets) descrevem como os elementos HTML devem se apresentar na tela. Ele é responsável pela aparência da página.

```
<p style='color: blue;'>Sou um parágrafo azul.</p>
```

- O atributo `style` é uma das maneiras de mexer na aparência utilizando CSS. No exemplo,
  - `color` é uma **property** do CSS e
  - `blue` é um **value** do CSS.

- Para associar esses pares **properties/values** aos elementos de um DOM, existe uma ferramenta chamada **CSS selectors**. Assim como fazemos com XML, podemos usar esses seletores (através do pacote `rvest`) para extrair os nós de uma página HTML.

CSS

- Abaixo vemos um `.html` e um `.css` que é usado para estilizar o primeiro. Se os nós indicados forem encontrados pelos seletores do CSS, então eles sofrerão as mudanças indicadas.

Seletores CSS vs. XPath

- A grande vantagem do XPath é permitir que acessemos os filhos, pais e irmãos de um nó. De fato os seletores CSS são mais simples, mas eles também são mais limitados.

- O bom é que se tivermos os seletores CSS, podemos transformá-los sem muita dificuldade em um query XPath:

    - Seletor de tag: `p` = `//p`
    - Seletor de classe: `.azul` = `//*[@class='azul']`
    - Seletor de id: `#meu-p-favorito` = `//*[@id='meu-p-favorito']`

- Além disso, a maior parte das ferramentas que utilizaremos ao longo do processo trabalham preferencialmente com XPath.

Seletores CSS vs. XPath

```
html <- read_html("static/html_exemplo_css_a_parte.html")
xml_find_all(html, "//p")
```

```
#> {xml_nodeset (3)}
#> [1] <p>Sou um parágrafo normal.</p>
#> [2] <p class="azul">Sou um parágrafo azul.</p>
#> [3] <p id="meu-p-favorito" class="azul">Sou um parágrafo azul e negrito.</p>
```

```
xml_find_all(html, "//*[@class='azul']")
```

```
#> {xml_nodeset (2)}
#> [1] <p class="azul">Sou um parágrafo azul.</p>
#> [2] <p id="meu-p-favorito" class="azul">Sou um parágrafo azul e negrito.</p>
```

Seletores CSS vs. XPath

```
rvest::html_nodes(html, ".azul")
```

```
#> {xml_nodeset (2)}
#> [1] <p class="azul">Sou um parágrafo azul.</p>
#> [2] <p id="meu-p-favorito" class="azul">Sou um parágrafo azul e negrito.</p>
```

- Note que `//p` indica que estamos fazendo uma busca na tag `p`, enquanto `//*` indica que estamos fazendo uma busca em qualquer tag.

Exercício (eu)

Acesse o site de buscas DuckDuckGo.com. Baixe a página de buscas. Dica: use a função `httr::GET()`.

```
library(httr)
GET("https://duckduckgo.com")
```

```
#> Response [https://duckduckgo.com/]
#>   Date: 2020-04-24 21:11
#>   Status: 200
#>   Content-Type: text/html; charset=UTF-8
#>   Size: 5.42 kB
#> <!DOCTYPE html>
#> <!--[if IEMobile 7 ]> <html lang="en_US" class="no-js iem7"> <![endif]-->
#> <!--[if lt IE 7]> <html class="ie6 lt-ie10 lt-ie9 lt-ie8 lt-ie7 no-js" lang="...
#> <!--[if IE 7]>    <html class="ie7 lt-ie10 lt-ie9 lt-ie8 no-js" lang="en_US">...
#> <!--[if IE 8]>    <html class="ie8 lt-ie10 lt-ie9 no-js" lang="en_US"> <![end...
#> <!--[if IE 9]>    <html class="ie9 lt-ie10 no-js" lang="en_US"> <![endif]-->
#> <!--[if (gte IE 9)|(gt IEMobile 7)|!(IEMobile)|!(IE)]><!--><html class="no-js...
#>
```

Exercício (nós)

Examine o código-fonte da página para encontrar o elemento correspondente à caixa de busca e copie o seu XPath pelo navegador. Esse XPath é apropriado? Por que?

```
//*[@id="search_form_input_homepage"]
```

Uma forma mais simples talvez fosse

```
//input[@name="q"]
```

Exercício (vocês)

Examine a aba de rede do inspetor do seu navegador. Quando você faz uma busca, qual requisição corresponde à mesma? Reproduza essa requisição com o pacote `httr`. Dica: use o parâmetro `query` para enviar a requisição correta.

```
GET("https://duckduckgo.com", query = list(q = "R", t = "h_"))
```

```
#> Response [https://duckduckgo.com/?q=R&t=h_]
#>   Date: 2020-04-24 21:11
#>   Status: 200
#>   Content-Type: text/html; charset=UTF-8
#>   Size: 26.2 kB
```

Iteração

O fluxo do web scraping

- Sempre que fazemos um web scraper é bom seguir um fluxo definido
- Por enquanto já foram apresentados elementos da maior parte do passo-a-passo, mas nada foi dito sobre a iteração

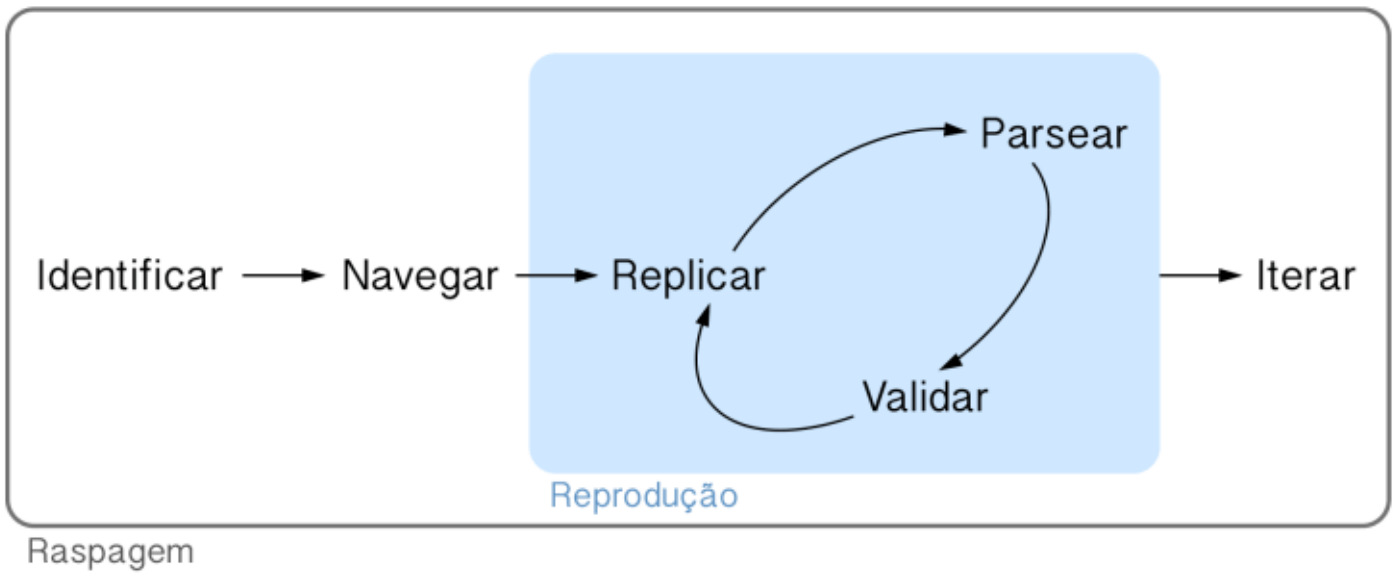

Por que iterar?

- Dificilmente queremos fazer uma tarefa de web scraping uma vez só (senão bastaria baixar a página uma vez e raspá-la)
- Podemos querer baixar muitas páginas de uma vez ou uma página a cada certo tempo
- Iteração, tratamento de erros e automatização passam a ser relevantes
  - O pacote `purrr` nos ajudará a iterar
  - O pacote `purrr` retornará para tratar qualquer erro que possa aparecer
  - O pacote `cronR` nos ajudará a agendar a execução de scripts
- Se você estiver interessado em aprender mais, veja nosso curso de Deploy

Iterar

- Iteração é um padrão de programação extremamente comum que pode ser altamente abreviado

```
nums <- 1:10
resp <- c()
for (i in seq_along(nums)) {
  resp <- c(resp, nums[i] + 1)
}
resp
```

```
#>  [1]  2  3  4  5  6  7  8  9 10 11
```

```
library(purrr)
map_dbl(nums, ~.x + 1)
```

```
#>  [1]  2  3  4  5  6  7  8  9 10 11
```

A função map

- A função `map()` recebe um vetor ou uma lista de entrada e aplica uma função em cada elemento do mesmo
- Podemos especificar o formato da saída com a família de funções `map_***()`
- A função pode ser declarada externamente, internamente ou através de um *lambda*

```
soma_um <- function(x) {
  x + 1
}

map(nums, soma_um)
map(nums, function(x) x + 1)
map(nums, ~.x + 1)
```

Utilidade do map

- Se tivermos uma lista de URLs, podemos iterar facilmente em todos sem abrir mão da sintaxe maravilhosa do Tidyverse

```
urls <- c(
  "https://en.wikipedia.org/wiki/R_language",
  "https://en.wikipedia.org/wiki/Python_(programming_language)"
)

urls %>%
  map(read_html) %>%
  map(xml_find_first, "//h1") %>%
  map_chr(xml_text)
```

```
#> [1] "R (programming language)"      "Python (programming language)"
```

Tratando problemas

- Ao repetir uma tarefa múltiplas vezes, não podemos garantir que toda execução funcione
- O R já possui o `try()` e o `tryCatch()`, mas o `purrr` facilita ainda mais o trabalho

```
maybe_read_html <- possibly(read_html, NULL)

read_html("https://errado.que")
```

```
#> Error in open.connection(x, "rb"): Could not resolve host: errado.que
```

```
maybe_read_html("https://errado.que")
```

```
#> NULL
```

Agendamento

- Infelizmente o pacote mais comum (`cronR`) não funciona no Windows, nele é necessário usar o `taskscheduleR`

```
library(cronR)
cmd <- cron_rscript("CAMINHO PARA SCRIPT")

cron_add(cmd, "daily", "00:00")
cron_add(cmd, "daily", "14:20", days_of_week = c(0, 3, 5))
cron_add(cmd, "monthly", "10:30", days_of_month = "first")
cron_add(cmd, '@reboot')
```

- Também é possível utilizar uma interface interativa no RStudio em **Addins > Schedule R scripts**

Exercício (eu)

Na página da Wikipédia, encontrar o objeto correspondente à tabela lateral de informações. Pegar apenas os elementos correspondentes a links.

```
links <- "https://en.wikipedia.org/wiki/R_language" %>%
  read_html() %>%
  xml_find_all("//table[@class='infobox vevent']//a")

head(links)
```

```
#> {xml_nodeset (6)}
#> [1] <a href="/wiki/File:R_logo.svg" class="image"><img alt="R logo.svg" src=" ...
#> [2] <a href="/wiki/File:R_Terminal.png" class="image"><img alt="R Terminal.pn ...
#> [3] <a href="/wiki/Programming_paradigm" title="Programming paradigm">Paradig ...
#> [4] <a href="/wiki/Multi-paradigm_programming_language" class="mw-redirect" t ...
#> [5] <a href="/wiki/Array_programming" title="Array programming">Array</a>
#> [6] <a href="/wiki/Object-oriented_programming" title="Object-oriented progra ...
```

Exercício (nós)

Extrair todos os URLs dos links e completá-los com o resto do caminho da Wikipédia. Continuar usando apenas *pipes*.

```
urls <- "https://en.wikipedia.org/wiki/R_language" %>%
  read_html() %>%
  xml_find_all("//table[@class='infobox vevent']//a") %>%
  xml_attr("href") %>%
  paste0("https://en.wikipedia.org", .)

head(urls)
```

```
#> [1] "https://en.wikipedia.org/wiki/File:R_logo.svg"
#> [2] "https://en.wikipedia.org/wiki/File:R_Terminal.png"
#> [3] "https://en.wikipedia.org/wiki/Programming_paradigm"
#> [4] "https://en.wikipedia.org/wiki/Multi-paradigm_programming_language"
#> [5] "https://en.wikipedia.org/wiki/Array_programming"
#> [6] "https://en.wikipedia.org/wiki/Object-oriented_programming"
```

Exercício (vocês)

Baixar todas as páginas da Wikipédia. Dicas: use `possibly()` para impedir erros quando o URL for inválido; procure saber sobre a função `map2()` para iterar em mais de uma lista; salve os arquivos com `GET(..., write_disk(path))`.

```
paths <- paste0(dir, seq_along(urls), ".html")

maybe_get <- function(url, path) {
  possibly(GET, NULL)(url, write_disk(path))
}

out <- map2(urls, paths, maybe_get)
length(compact(out))
```

```
#> [1] 32
```

Paralelismo

O que isso significa?

- Antigamente, computadores eram capazes de executar apenas uma sequência de comandos por vez
- Avanços tecnológicos permitiram que o processador fosse capaz de fazer "malabarismo" com diversos processos
- Paralelismo (ou multiprocessamento) chegou apenas com os primeiros *dual-core*

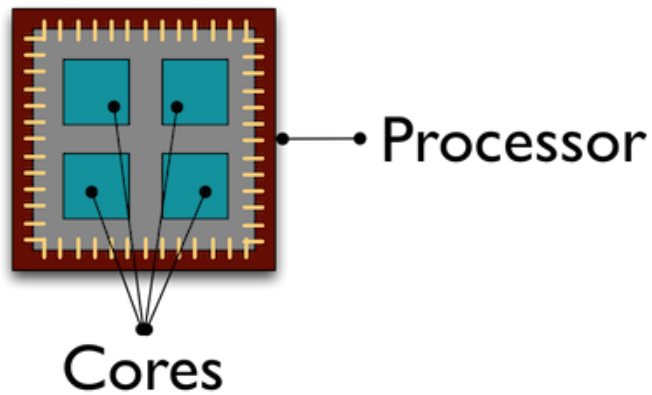

Em mais detalhes

- A unidade de processamento central pode ter mais de um **núcleo** (*multicore*)
- Um **processo** é composto por uma sequência de comandos ou tarefas
- Cada núcleo consegue executar apenas um **comando** por vez
- Os comandos de um processo podem ser interrompidos para que sejam executados os de outro (*multitasking*)
- O computador pode executar várias tarefas simultaneamente escalonando os comandos para seus diferentes núcleos (*multithreading*)
- Muitos computadores possuem **núcleos virtuais**, permitindo dois comandos por vez em cada núcleo (*hyperthreading*)

Exemplo mínimo

O pacote `parallel` já vem instalado junto com o R e consegue rodar comandos paralelamente tanto no Windows quanto em outros sistemas. Por padrão, ele quebra a tarefa em 2.

```
library(parallel)
library(microbenchmark)

microbenchmark(
  seq = map_dbl(1:10000, function(x) x + 1),
  par = mclapply(1:10000, function(x) x + 1)
)
```

```
#> Unit: milliseconds
#>  expr       min        lq      mean    median        uq      max neval
#>   seq  5.195802  7.937328  9.906303  9.343716 11.59754 19.39558   100
#>   par 10.505307 12.466380 16.300531 14.895999 18.19405 36.48882   100
```

Futuros

- O pacote `future` expande o pacote `parallel`, permitindo o descolamento de tarefas da sessão principal
    - Ele pode operar em 2 níveis: *multicore* e *multissession*
- Em cima do `future`, for construído o `furrr` com o objetivo de emular a sintaxe do `purrr` para processamento paralelo
- Diferentemente do `parallel`, o `future` é capaz de descobrir sozinho o número de núcleos virtuais do computador

```
library(future)
availableCores()
```

```
#> system
#>      8
```

Exercício (eu)

Estabelecer um plano de execução paralela com a função `plan()`. Entender a diferença entre todos os planos disponíveis.

```
plan(multiprocess)
```

- `sequential`: não executa em paralelo, útil para testes
- `multicore`: mais eficiente, não funciona no Windows nem dentro do RStudio
- `multisession`: abre novas sessões do R, mais pesado para o computador
- `multiprocess`: escolhe o melhor entre `multicore` e `multisession`

Exercício (nós)

Criar uma função que retorna o primeiro parágrafo de uma página da Wikipédia dado o fim de seu URL (como "/wiki/R_language"). Dicas: textos são denotados pela *tag* <p> em HTML; pule o elemento de classe "mw-empty-elt".

```
download_wiki <- function(url) {
  url %>%
    paste0("https://en.wikipedia.org", .) %>%
    read_html() %>%
    xml_find_first("//p[not(@class='mw-empty-elt')]") %>%
    xml_text()
}
```

Exercício (vocês)

Executar a função anterior em paralelo para todas as páginas baixadas no exercício de iteração. Dicas: utilize `future_map()` do pacote `furrr`; não se esqueça do `possibly()`"!

```
library(furrr)

prgs <- "https://en.wikipedia.org/wiki/R_language" %>%
  read_html() %>%
  xml_find_all("//table[@class='infobox vevent']//a") %>%
  xml_attr("href") %>%
  future_map(possibly(download_wiki, ""))

prgs[[3]]
```

```
#> [1] "Programming paradigms are a way to classify programming languages based on the
```

Selenium

O que é Selenium?

- Selenium é uma ferramenta que permite **automatizar um navegador**!
- Suporta alguns *backends* diferentes: PhantomJS, Firefox, Chrome, etc.
- Diferentemente do web scraping normal, não precisamos nos preocupar com nenhuma requisição HTTP
    - O Selenium literalmente cria um navegador invisível para o qual você pode passar as **ações** a serem tomadas
    - Por ser uma sessão interativa, não há dificuldades em exibir conteúdo dinâmico
    - Não é necessário compreender o *networking* do site: tudo é *headless*

Por que não usá-lo sempre?

- Vantagens:
  - Fácil de entender
  - Permite raspar dados dinâmicos
  - Permite *screen shots*
- Desvantagens:
  - Lento e de difícil paralelização
  - Bastante sensível
  - `RSelenium` está **completamente quebrado**

WebDriver

- Não existe uma diferença real entre "Selenium" e "WebDriver"
  - O nome correto da ferramenta é Selenium WebDriver
- A diferença está no R: pacotes `RSelenium` e `webdriver`
  - `RSelenium` essencialmente não funciona
  - `webdriver` foi feito pela própria RStudio para resolver o problema
- O `webdriver` funciona somente com o PhantomJS, mas isso não é necessariamente um problema
- Instalar é fácil, fazer funcionar é mais ainda

PhantomJS

- O PhantomJS é um navegador *headless* baseado em JavaScript feito especificamente para interação automatizada com páginas da web

```
library(webdriver)
# webdriver::install_phantomjs()

pjs <- run_phantomjs()
pjs
```

```
#> $process
#> PROCESS 'phantomjs', running, pid 148392.
#>
#> $port
#> [1] 5363
```

```
ses <- Session$new(port = pjs$port)
```

Exemplo mínimo

```
ses$go("https://google.com")
ses$takeScreenshot(file = arq)
```

Elementos

- `ses$findElement()` retorna um elemento da página dado um seletor ou XPath para o mesmo
  - É uma função embutida na sessão (assim como `takeScreenshot()` e `go()`)
- `elem$click()` clica em um elemento, enquanto `elem$sendKeys()` "envia" uma tecla para o elemento
  - São funções embutidas no elemento retornado por `findElement()`
  - A lista `key` contém uma série de teclas que podem ser enviadas (como ENTER, etc.)
  - Ao invés de `elem$sendKeys()` podemos usar `elem$setValue()` para escrever um texto no elemento caso isso seja possível

Exercício (eu)

Encontrar a página de Fundos de Investimento da XP. Criar uma sessão `webdriver` para ir até esta página.

```
xp <- paste0(
  "https://institucional.xpi.com.br/investimentos/",
  "fundos-de-investimento",
  "/lista-de-fundos-de-investimento.aspx"
)
ses$go(xp)
ses$takeScreenshot(file = arq)
```

Exercício (eu)

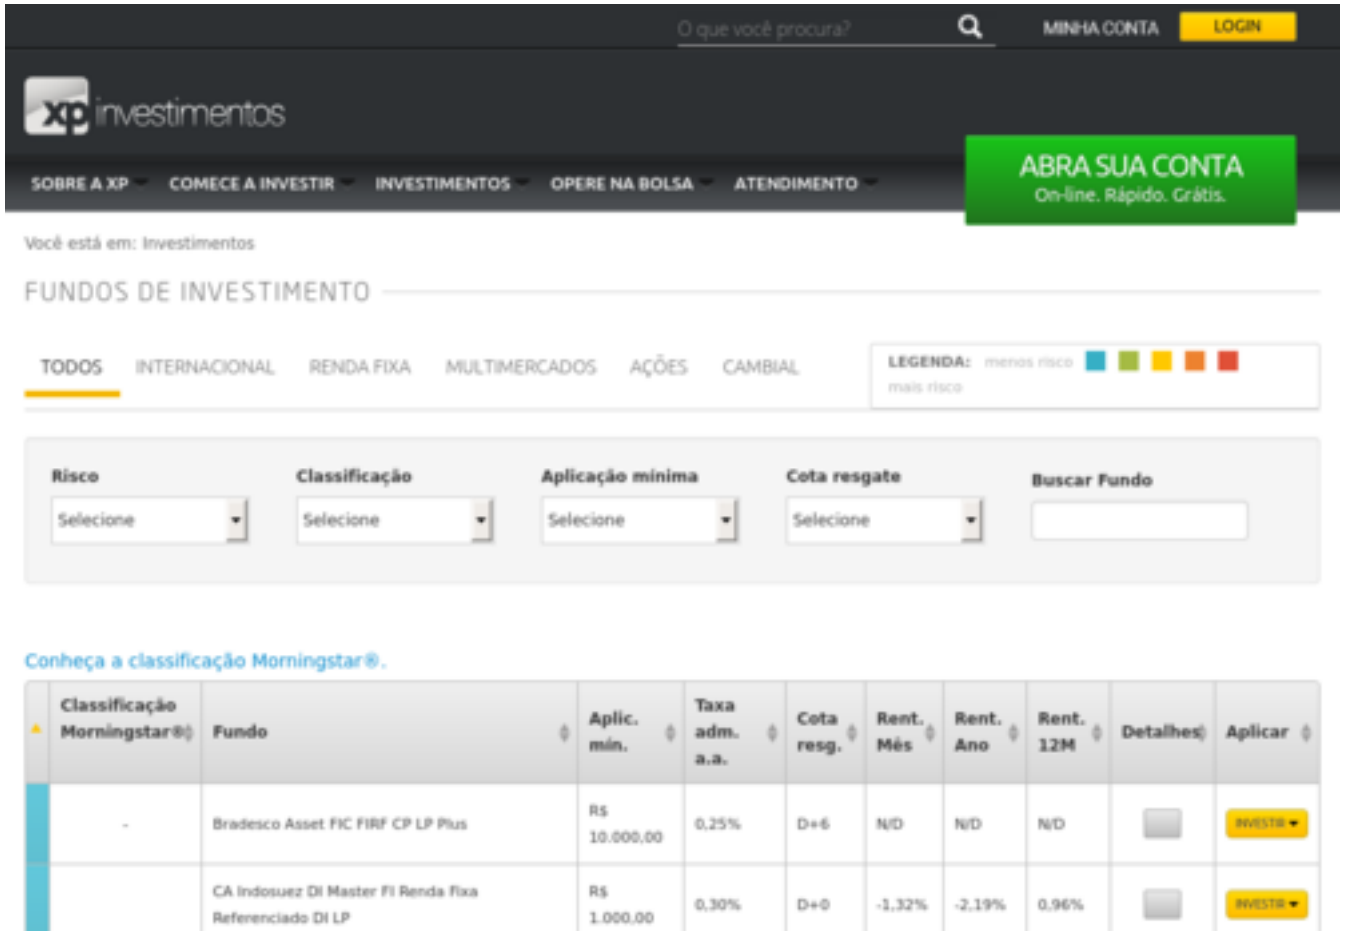

Exercício (nós)

Fazer a sessão `webdriver` clicar na aba "Internacional" no topo da página.

```
elem <- ses$findElement(xpath = '//a[@href="#referenciado"]')
elem$click()
ses$takeScreenshot(file = arq)
```

Exercício (nós)

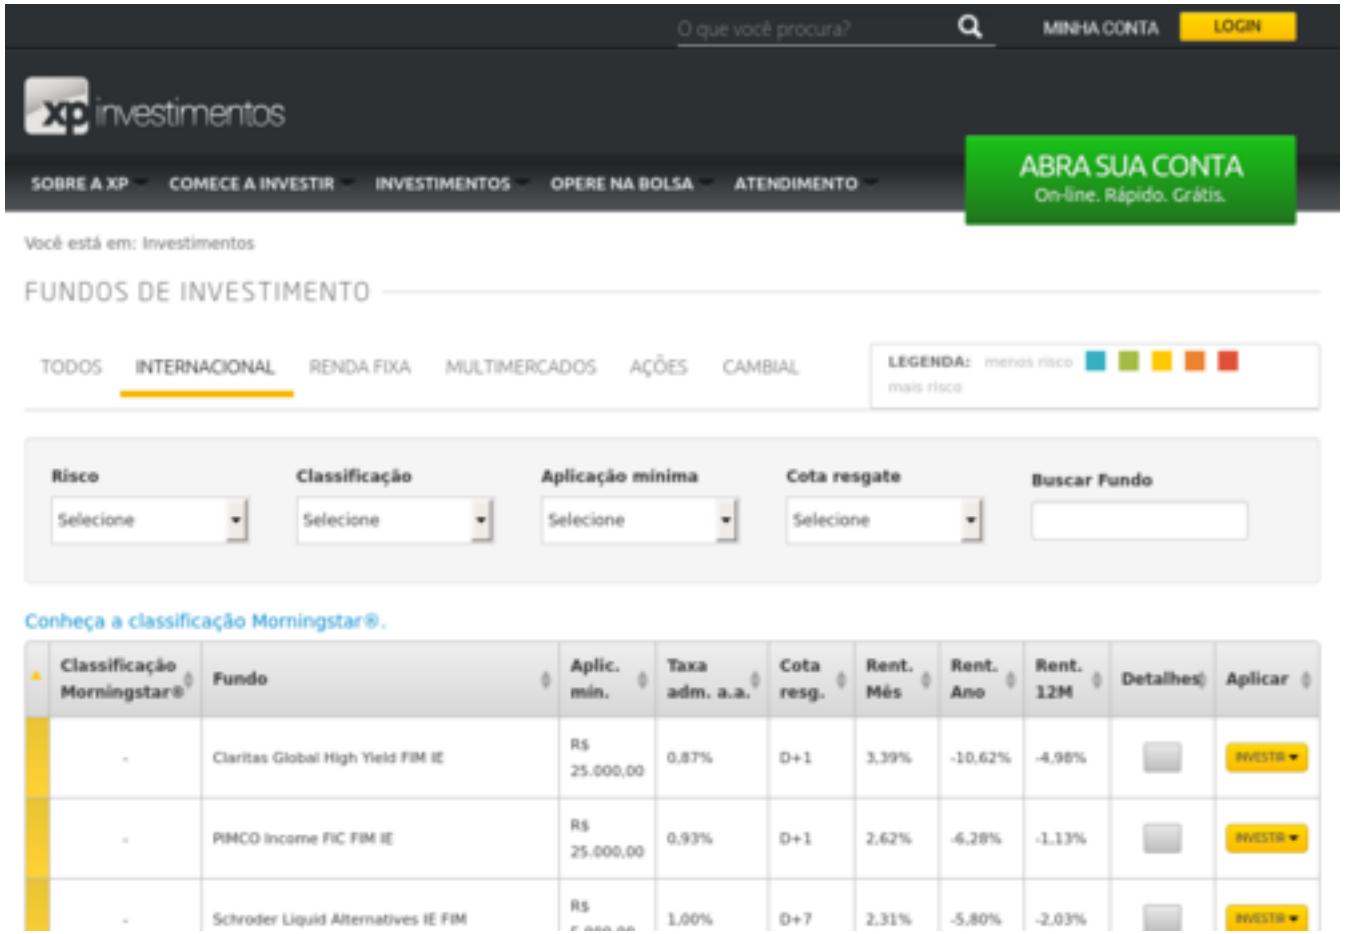

Exercício (vocês)

Filtrar apenas os fundos de alto risco. Dica: podemos selecionar um elemento de uma lista com as setas do teclado (analisar key) ou podemos obter a estrutura da lista de seleções.

```
tab <- "//div[@id='tableReferenciadoRisk']"
opt <- paste0(tab, "/span/select/option[@value='5']")

elem <- ses$findElement(xpath = tab)
elem$click()
Sys.sleep(2)
elem <- ses$findElement(xpath = opt)
elem$click()

ses$takeScreenshot(file = arq)
```

Exercício (vocês)

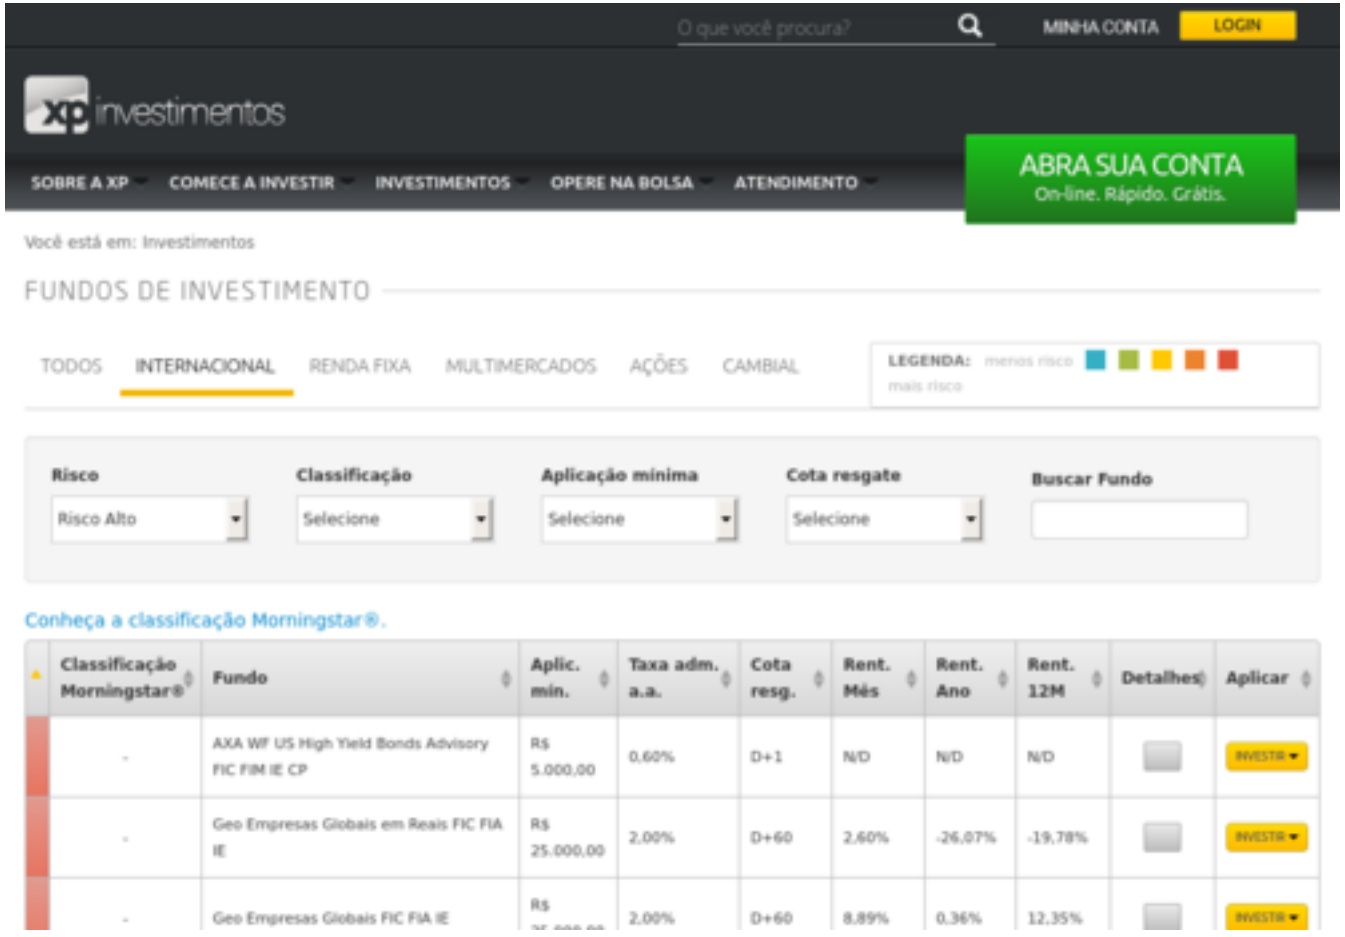

Quer mais?

- O PhantomJS, apesar de muito capaz, ainda não consegue exibir todo o conteúdo dinâmico de uma página
- Para solucionar esse problema, é necessário usar o RSelenium com um navegador de verdade como backend
  - Nem sempre a instalação do `RSelenium` funciona e em alguns sistemas operacionais há outras dependências
  - A documentação do `RSelenium` está atrasadas, dificultando qualquer pesquisa
  - O método sugerido para utilizar navegadores externos depende do Docker, um programa sem relação com o R
- Não use `RSelenium` caso não seja estritamente necessário!

Demonstração

- As funções do `RSelenium` são parecidas com as do `webdriver`, mas envolvem um mais esforço
- No exemplo abaixo, o `RSelenium` abre uma aba do Firefox no meu computador e executa todos os comandos ao vivo nela

```
library(RSelenium)
drv <- rsDriver(browser = "firefox", verbose = FALSE)

drv$client$navigate("https://google.com")
elem <- drv$client$findElement("xpath", "//input[@name='q']")
elem$sendKeysToElement(list("ibovespa", key = "enter"))

Sys.sleep(2)
drv$client$screenshot(file = arq)
```

Demonstração

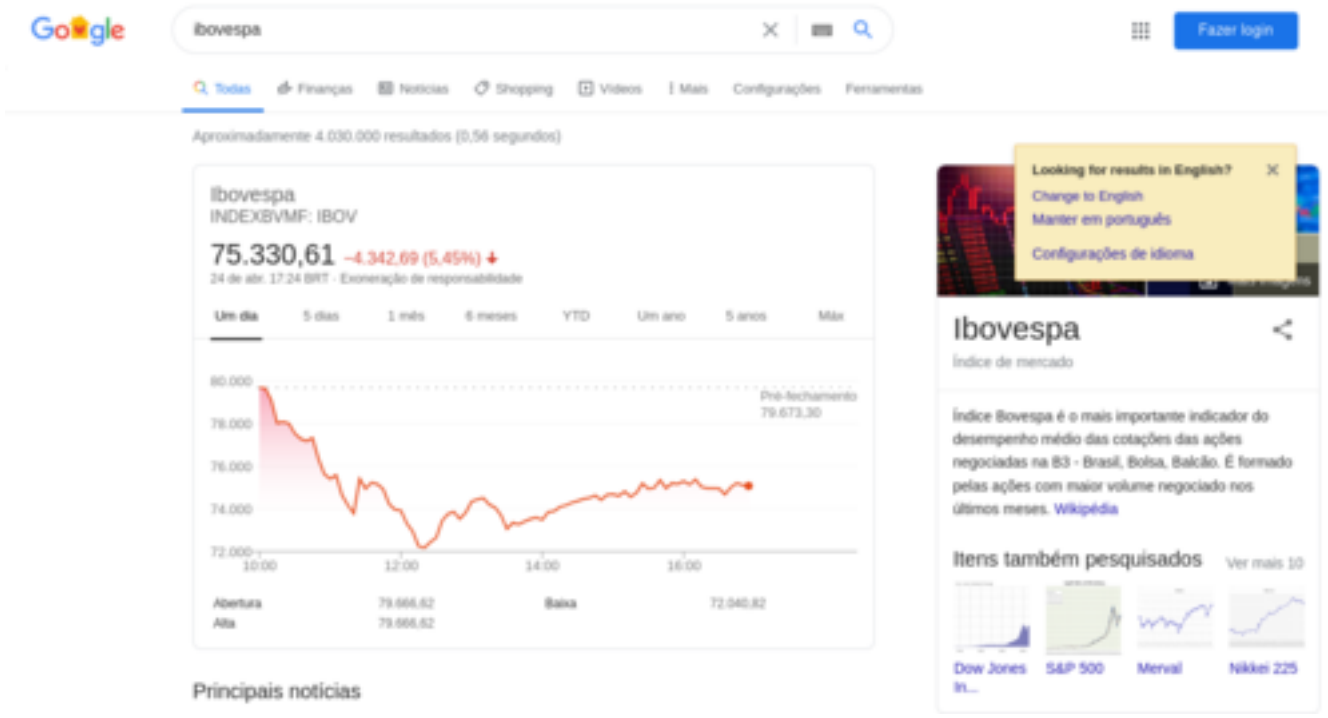

Mas com o webdriver...

- Note a presença do gráfico interativo na imagem anterior, isso não é possível com o `webdriver`
- Pelas limitações do PhantomJS, nem todo elemento dinâmico pode ser renderizado na tela
    - É possível usar o `webdriver` com Docker também, mas nesse caso é melhor recorrer ao `RSelenium`

```
ses$go("https://google.com")
elem <- ses$findElement(xpath = "//input[@name='q']")
elem$sendKeys("ibovespa", key$enter)

Sys.sleep(2)
ses$takeScreenshot(file = arq)
```

Mas com o webdriver...

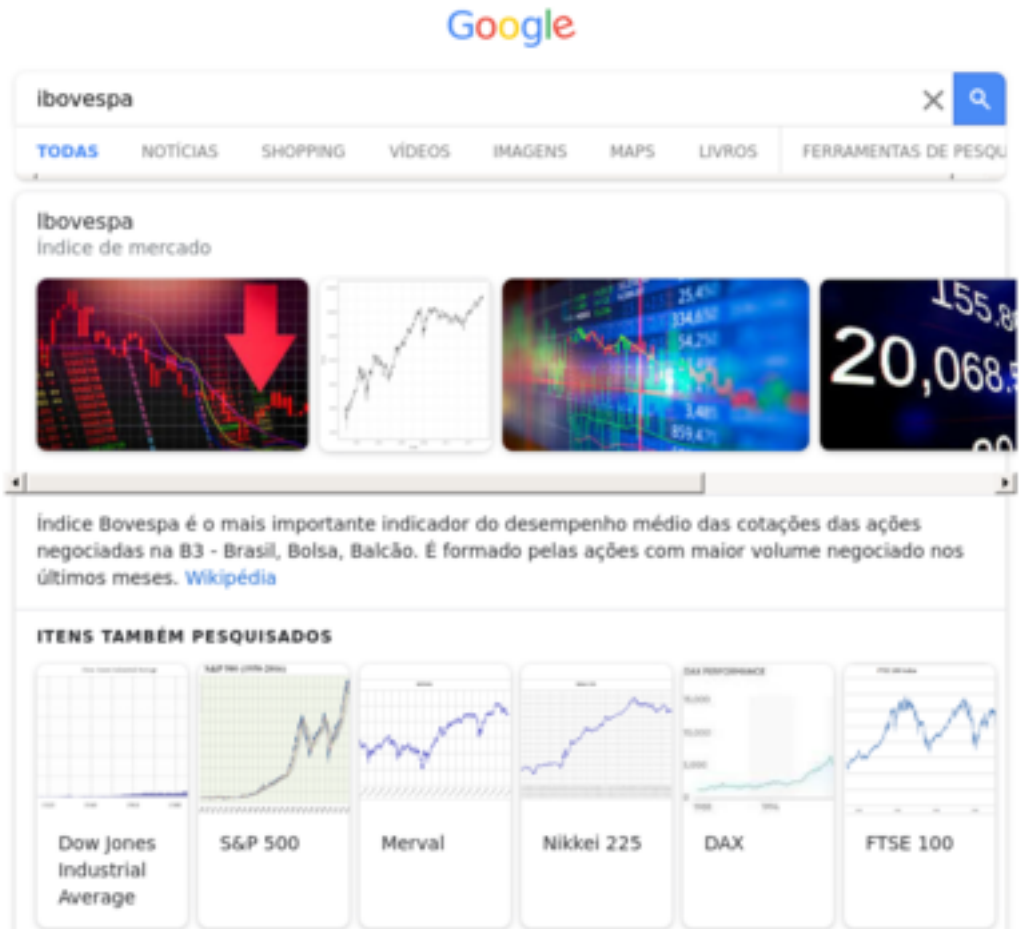

Miscelânea

O DEJT

- O Diário Eletrônico da Justiça do Trabalho é publicado (quase) todo dia e contém todas as movimentações de vários tribunais do trabalho
- O nosso objetivo é baixar o PDF do diário para um dia específico

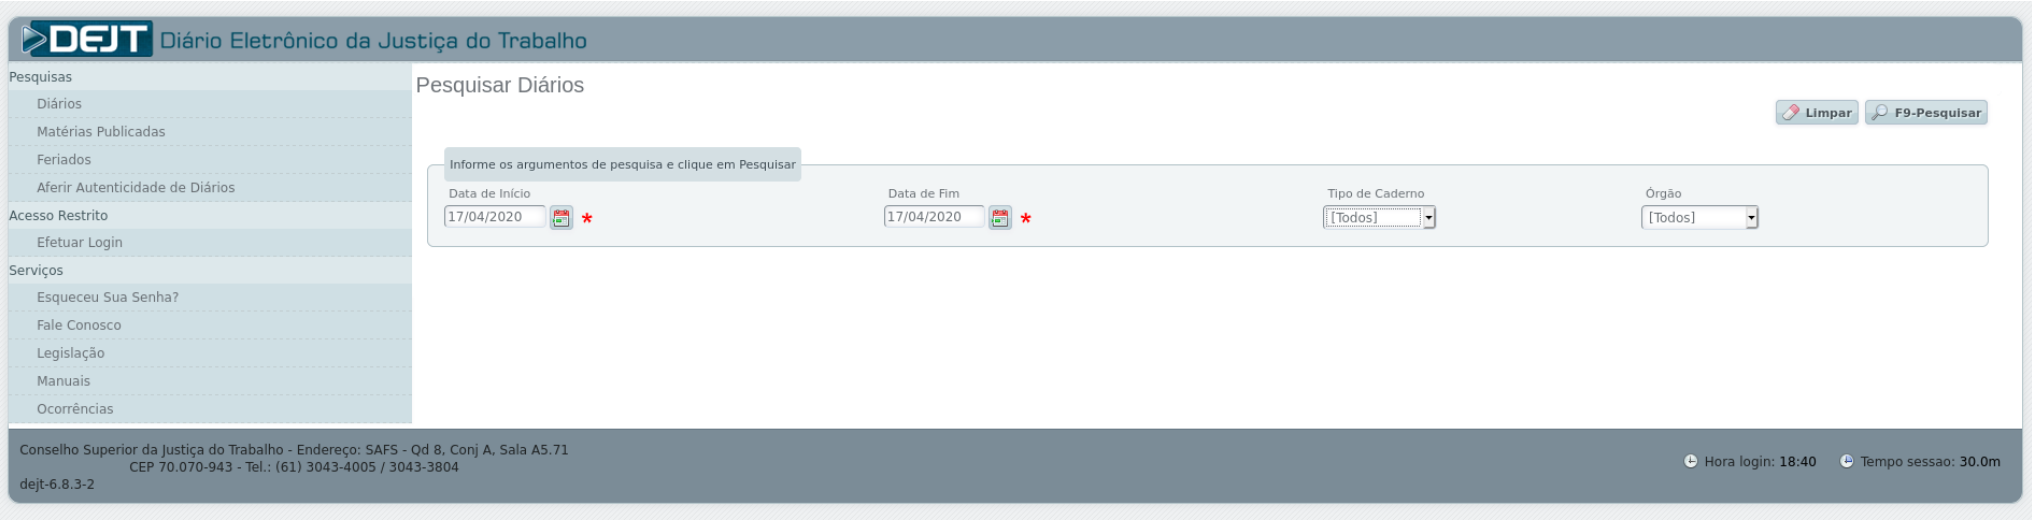

A busca

- Para buscar os diários de um dia, basta entrar no site e escolher o dia correspondente
- Analisando o POST, vemos que não há muita dificuldade em reproduzir a requisição

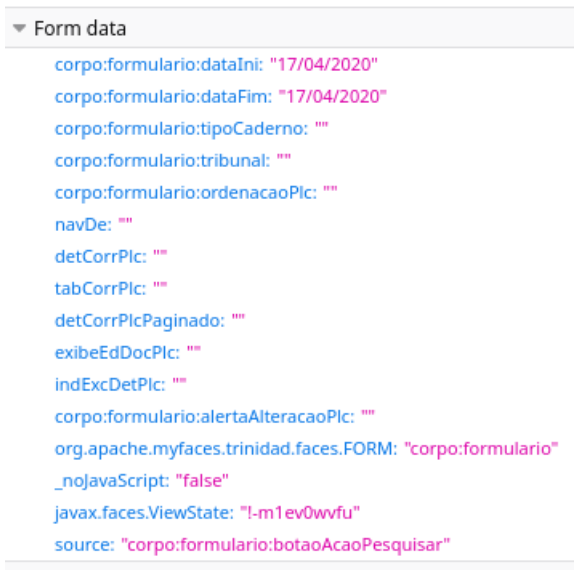

Requisição da busca

```
body <- list(
  "corpo:formulario:dataIni" = "17/04/2020",
  "corpo:formulario:dataFim" = "17/04/2020",
  "corpo:formulario:tipoCaderno" = "",
  "corpo:formulario:tribunal" = "",
  "corpo:formulario:ordenacaoPlc" = "",
  "navDe" = "",
  "detCorrPlc" = "",
  "tabCorrPlc" = "",
  "detCorrPlcPaginado" = "",
  "exibeEdDocPlc" = "",
  "indExcDetPlc" = "",
  "org.apache.myfaces.trinidad.faces.FORM" = "corpo:formulario",
  "_noJavaScript" = "false",
  "javax.faces.ViewState" = "!-m1ev0wvfu",
  "source" = "corpo:formulario:botaoAcaoPesquisar"
)
```

Reproduzindo a busca

```
url <- "https://dejt.jt.jus.br/dejt/f/n/diariocon"
POST(url, body = body)
```

```
#> Error in curl::curl_fetch_memory(url, handle = handle): SSL certificate problem: ur
```

- A primeira tentativa não funcionou por causa de um erro no certificado SSL
- SSL é o nome antigo para TLS (*Transport Layer Security*), uma ferramenta que permite que exista o HTTPS
    - HTTPS é a versão secura e criptografada do HTTP, o protocolo da *web*
- Essencialmente, isso quer dizer que a página do DEJT tem vulnerabilidade

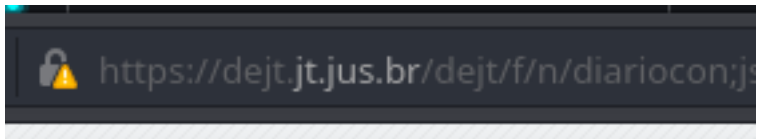

Reproduzindo a busca 2

```
resp <- POST(
  url, body = body,
  config(ssl_verifypeer = FALSE)
)
length(resp$content)
```

```
#> [1] 16947
```

- Apesar de a consulta ter funcionado, o tamanho da resposta (16kB) não está nem próximo do esperado
- Isso ocorre porque a página espera um POST do tipo formulário
    - A única diferença é o formato em que os dados serão enviados ao servidor

Reproduzindo a busca 3

```
resp <- POST(
  url, body = body, encode = "form",
  config(ssl_verifypeer = FALSE)
)
length(resp$content)
```

```
#> [1] 16947
```

- Ainda sem sucesso, precisamos começar a conferir o formulário
- Se sairmos da página e tentarmos copiar o POST de novo, notaremos que o Viewstate mudou

Viewstate

- O JSF ViewState é um campo escondido que carrega consigo informações sobre o estado de uma sessão do navegador
- Ele é capaz de indicar para a próxima página acessada o que tinha acontecido até aquele momento
- No nosso caso o Viewstate é relevante apenas porque muitas páginas dependem dele para funcionar

```
# Procurando o Viewstate na página anterior à busca
viewstate <- url %>%
  GET(config(ssl_verifypeer = FALSE)) %>%
  content() %>%
  xml_find_first('//input[@name="javax.faces.ViewState"]') %>%
  xml_attr("value")
```

Reproduzindo a busca 4

```
body$javax.faces.ViewState <- viewstate
resp <- POST(
  url, body = body, encode = "form",
  config(ssl_verifypeer = FALSE)
)
length(resp$content)
```

```
#> [1] 47288
```

- Agora que a resposta está correta, podemos continuar a raspagem da página sem mais problemas
- Basta identificar como baixar cada um dos PDFs

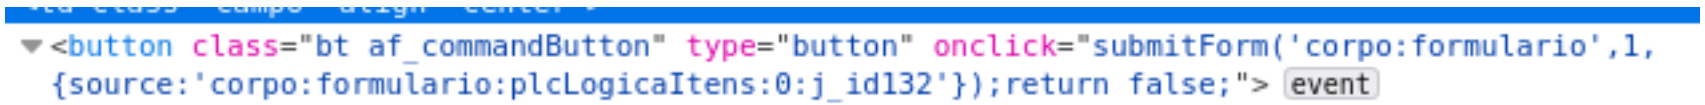

Encontrando o PDF

- Assim como outras páginas feitas com Java, grande parte dos elementos interativos do DEJT possui um identificador único
- No nosso caso, precisamos encontrar o ID dos PDFs antes de poder baixá-los

```
jid <- resp %>%
  read_html() %>%
  xml_find_all("//button") %>%
  xml_attr("onclick") %>%
  stringr::str_extract("(?<=plcLogicaItens:0:)j_id[0-9]+") %>%
  extract(!is.na(.))
```

Requisição do PDF

```
body2 <- list(
  "corpo:formulario:dataIni" = "17/04/2020",
  "corpo:formulario:dataFim" = "17/04/2020",
  "corpo:formulario:tipoCaderno" = "",
  "corpo:formulario:tribunal" = "",
  "corpo:formulario:ordenacaoPlc" = "",
  "navDe" = "",
  "detCorrPlc" = "",
  "tabCorrPlc" = "",
  "detCorrPlcPaginado" = "",
  "exibeEdDocPlc" = "",
  "indExcDetPlc" = "",
  "org.apache.myfaces.trinidad.faces.FORM" = "corpo:formulario",
  "_noJavaScript" = "false",
  "javax.faces.ViewState" = viewstate,
  "source" = paste0("corpo:formulario:plcLogicaItens:0:", jid)
)
```

Baixando o PDF

- Baixar um PDF funciona da mesma forma que baixar um HTML para o disco do computador, basta utilizar a função `write_disk()`

```
POST(
  url, body = body2,
  write_disk(arq, TRUE),
  config(ssl_verifypeer = FALSE)
)
```

```
#> Response [https://dejt.jt.jus.br/dejt/f/n/diariocon]
#>   Date: 2020-04-24 21:12
#>   Status: 200
#>   Content-Type: application/pdf
#>   Size: 9.46 MB
#> <ON DISK>  /home/clente/Downloads/teste.pdf
```

Fim

(Parabéns!)